

《机器学习课程设计》考察题目 – 半监督学习

一、任务描述

在图像识别、文本分类和医疗诊断等实际应用中，获取大量数据通常比较容易，但对数据进行人工标注往往需要较高的成本。半监督学习（Semi-Supervised Learning）旨在利用少量有标签数据和大量无标签数据共同训练模型，从而降低对人工标注数据的依赖。本实验需要同学们利用机器学习模型研究少量标签情况下的分类问题，并设计合理的半监督学习方法。

二、目标

- 掌握半监督学习的基本方法和模型。
- 理解有标签数据和无标签数据在模型训练中的作用。
- 能使用合理的评价指标分析模型表现。

三、数据集

Fashion-MNIST Dataset: (<https://github.com/zalandoresearch/fashion-mnist>)

数据：70,000 张 28×28 的灰度服饰图像，共 10 个类别

训练集：60,000 个样本

测试集：10,000 个样本

标签：服饰所属类别（0-9）

四、作业内容

作业至少包含以下内容：

1. 数据预处理：数据归一化、训练集与测试集划分等。
2. 建模与实验：首先使用完整训练标签建立分类模型，并逐步减少有标签训练样本的比例（如 10%、5%、1%），分析标签数量对模型性能的影响。
3. 半监督学习：在少量有标签数据的基础上，利用剩余的无标签数据设计半监督学习方法，并与仅使用有标签数据训练的监督学习模型进行比较，分析利用无标签数据是否总是能带来性能提升？
4. 模型评估：使用合理的评价指标评价模型，并分析不同标签比例以及不同半监督学习方法的实验结果。

5. 挑战题目（可选）：假设现在可继续额外标注少量无标签样本，应如何选择最值得标注的样本，使模型能够以尽可能少的人工标注获得尽可能好的性能？请对此设计一种样本选择和模型训练方法。

五、提交说明

- **项目文件夹：**包含代码、README
- **项目报告：**以 PDF 格式提交，封面使用提供的模板，内容建议包括：
 - 问题定义与理解
 - 数据分析及处理
 - 模型构建
 - 实验结果与分析
 - 结论与可能改进
- **提交方式：**将报告和代码打包，智能科学 2401 班同学发送到 wwh35@hust.edu.cn，智能科学 2402 班同学发送到 m202674511@hust.edu.cn，压缩文件命名为《班级》-《学号》-《姓名》，邮件主题为机器学习课设-《班级》-《姓名》。
- **截止日期：**在 2026 年 10 月 8 日 23:59pm 之前提交。